

МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИМЕНИ М. В. ЛОМОНОСОВА

ФАКУЛЬТЕТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ И КИБЕРНЕТИКИ
КАФЕДРА МАТЕМАТИЧЕСКИХ МЕТОДОВ ПРОГНОЗИРОВАНИЯ

Мизинов Егор Романович

Исследование эффективности графовых нейронных сетей для решения задач прогнозирования пассажирских авиаперевозок

КУРСОВАЯ РАБОТА

Научный руководитель:
доцент, к.ф.-м.н.
Прокофьев Петр Александрович

Москва, 2026

Содержание

1 Введение **2**

2 Постановка задачи **2**
2.1 Дано 2
2.2 Найти 3
2.3 Критерий качества 3

3 Обзор методов прогнозирования **3**
3.1 Табличный подход: CatBoost 4
3.2 Графовые свёрточные сети (GCN) 4
3.3 Графовые сети с механизмом внимания (GAT) 5

4 Описание экспериментов **6**
4.1 Характеристики данных и схема разбиения 6
4.2 Настройка моделей и гиперпараметры 7
4.3 Анализ результатов и сравнение моделей 7

5 Заключение **8**

1 Введение

В современной авиационной индустрии точность прогнозирования пассажирского спроса является критическим фактором для динамического ценообразования и эффективного управления ресурсами. Одним из главных индикаторов спроса выступает пользовательская активность — количество поисковых запросов и переходов на конкретные рейсы.

Однако существующие методы прогнозирования, основанные на классических алгоритмах машинного обучения, рассматривают каждый рейс изолированно и не учитывают взаимосвязи между маршрутами (например, стыковочные или обратные рейсы). Это приводит к снижению точности прогнозов.

Задача предсказания спроса имеет важный прикладной смысл для стратегического планирования авиакомпаний. Точное моделирование сетевых зависимостей позволяет оценивать потенциальную востребованность новых, еще не существующих в расписании маршрутов на основе данных по смежным направлениям. Это дает авиаперевозчикам возможность принимать решения об открытии новых рейсов и направлений.

Объектом исследования является процесс формирования пользовательского спроса на авиаперевозки, зафиксированный через активность в системах поиска и бронирования.

Предметом исследования выступают алгоритмы графовых нейронных сетей, предназначенные для решения задачи регрессии на графовых структурах.

Целью данной работы является разработка и исследование модели на основе графовых нейронных сетей для прогнозирования количества кликов на авиарейсы за 2, 4, 6 и 8 недель до рейса.

Специфика прогнозирования в авиационной отрасли заключается в том, что данные о спросе являются нестационарными и подвержены выраженному влиянию временных факторов.

2 Постановка задачи

2.1 Дано

Маршрутная сеть авиаперевозок задаётся в виде ориентированного графа

$$G = (V, E), \tag{1}$$

где:

- $V = \{v_1, v_2, \ldots, v_n\}$ — множество вершин, соответствующих аэропортам;
- $E = \{e_{ij}\}$ — множество ориентированных рёбер, соответствующих прямым авиарейсам из аэропорта i в аэропорт j.

Каждому ребру e_{ij} сопоставлены:

- вектор локальных признаков $\mathbf{x}_{ij} \in \mathbb{R}^d$ (авиакомпания, время вылета, день недели, месяц, тип воздушного судна и т.д.);
- целевая переменная $y_{ij}^T \in \mathbb{Z}_{\geq 0}$ — фактическое количество кликов пользователей по данному рейсу за T недель до даты вылета.

Временной горизонт прогнозирования принимает значения:

$$T \in \{2,\ 4,\ 6,\ 8\}. \tag{2}$$

Задана историческая обучающая выборка

$$\mathcal{D}_{\text{train}} = \big\{(e_{ij},\ \mathbf{x}_{ij},\ y_{ij}^{T})\big\}, \tag{3}$$

сформированная по данным за период с 1 июня 2022 года по 30 апреля 2024 года после исключения невостребованных рейсов (с нулевым спросом).

2.2 Найти

Требуется построить функцию прогноза

$$\hat{y}_{ij}^{T} = f\big(G,\ \mathbf{x}_{ij},\ T\big) \tag{4}$$

которая по известному графу маршрутной сети G, вектору признаков рейса $\mathbf{x}_{ij}$ и временному горизонту T вычисляет прогнозируемое количество кликов $\hat{y}_{ij}^{T}$. Необходимо, чтобы для каждого тестового ребра e_{ij} значение $\hat{y}_{ij}^{T}$ было максимально близко к истинному значению y_{ij}^{T}.

2.3 Критерий качества

Качество модели оценивается на тестовой выборке $\mathcal{D}_{\text{test}}$ отдельно для каждого временного горизонта $T \in \{2, 4, 6, 8\}$. Используются следующие метрики:

MAE (средняя абсолютная ошибка):

$$\text{MAE} = \frac{1}{|\mathcal{D}_{\text{test}}|} \sum_{(e_{ij},\, \mathbf{x}_{ij},\, y_{ij}^{T}) \in \mathcal{D}_{\text{test}}} |y_{ij}^{T} - \hat{y}_{ij}^{T}| \tag{5}$$

RMSE (среднеквадратичная ошибка):

$$\text{RMSE} = \sqrt{\frac{1}{|\mathcal{D}_{\text{test}}|} \sum_{(e_{ij},\, \mathbf{x}_{ij},\, y_{ij}^{T}) \in \mathcal{D}_{\text{test}}} (y_{ij}^{T} - \hat{y}_{ij}^{T})^2} \tag{6}$$

R^2 (коэффициент детерминации):

$$R^2 = 1 - \frac{\sum_{(e_{ij},\, \mathbf{x}_{ij},\, y_{ij}^{T}) \in \mathcal{D}_{\text{test}}} (y_{ij}^{T} - \hat{y}_{ij}^{T})^2}{\sum_{(e_{ij},\, \mathbf{x}_{ij},\, y_{ij}^{T}) \in \mathcal{D}_{\text{test}}} (y_{ij}^{T} - \bar{y}^{T})^2}, \tag{7}$$

где $\bar{y}^{T}$ — среднее значение целевой переменной на тестовой выборке для горизонта T.

Оптимизация параметров моделей производится по минимизации **RMSE** на валидационной выборке. Финальное сравнение моделей выполняется по всем трём метрикам.

3 Обзор методов прогнозирования

Для преодоления ограничений классических табличных моделей, не способных учитывать топологическую структуру маршрутной сети, в работе исследуются подходы на основе графовых нейронных сетей (Graph Neural Networks, GNN). Концептуально возможность применения нейросетевых архитектур к структурам произвольного графового вида была впервые предложена в работах M. Gori [1] и F. Scarselli [2], где обновление состояний узлов основывалось на итерационном поиске неподвижной точки.

Центральным понятием при работе с графовыми данными является *эмбеддинг (векторное представление)* — отображение исходного объекта (вершины или ребра графа) в низкоразмерное вещественное векторное пространство, сохраняющее скрытые семантические, структурные или топологические свойства данного объекта. В контексте данной работы эмбеддинги аэропортов (вершин) и рейсов (рёбер) позволяют нейросетевым архитектурам извлекать и агрегировать пространственный контекст авиасети.

Современные архитектуры представляют собой развитие этой идеи в сторону пространственных методов агрегации, моделирующих операцию свёртки непосредственно в окрестности вершин. В задаче регрессии в данной работе рассматриваются две такие базовые архитектуры, реализующие различные механизмы извлечения пространственного контекста авиасети, а также табличный подход CatBoost в качестве эталонной модели сравнения.

3.1 Табличный подход: CatBoost

В качестве базовой модели (*baseline*) — стандартного, проверенного подхода, относительно качества которого оценивается эффективность внедрения новых алгоритмов, — выступает алгоритм градиентного бустинга над решающими деревьями CatBoost [**?**]. Под градиентным бустингом понимается ансамблевый метод машинного обучения, основанный на последовательном построении композиции слабейших моделей (решающих деревьев), где каждое следующее дерево обучается минимизировать ошибку всех предыдущих.

Выбор данной модели в качестве эталона обусловлен структурой признакового пространства, которая содержит большое количество гетерогенных факторов: от числовых характеристик времени до категориальных признаков (коды аэропортов вылета и прилёта, идентификаторы авиакомпаний).

Однако ключевым ограничением CatBoost в рамках данной прикладной области является статичность контекста. Любые пространственные взаимосвязи и топологические зависимости между аэропортами должны проектироваться и задаваться вручную на этапе предобработки данных. Это лишает модель возможности гибко и адаптивно извлекать скрытые закономерности в динамической системе авиаперевозок, что мотивирует переход к графовым методам, описанным ниже.

3.2 Графовые свёрточные сети (GCN)

Рассмотрим типичный сценарий в авиаперевозках: группа пассажиров планирует маршрут из города A в город B, однако прямое сообщение между ними отсутствует. В этом случае перелёт осуществляется с пересадкой в хабовом аэропорту C. С точки зрения графовых данных это означает, что совокупный спрос на направление $A \to B$ фактически распределяется между двумя другими: $A \to C$ и $C \to B$. Любые изменения в деятельности аэропорта C повлекут за собой изменение интенсивности кликов и бронирований на всех связанных рейсах.

Кроме того, авиаперелёты характеризуются циклической зависимостью, обусловленной возвратными маршрутами: поиск билета из A в B с высокой вероятностью подразумевает последующий интерес к обратному направлению из B в A в рамках того же временного горизонта. Традиционные алгоритмы машинного обучения зачастую игнорируют эти взаимосвязи, рассматривая каждый рейс как изолированную запись.

Графовые свёрточные сети (Graph Convolutional Networks, GCN) [4] решают проблему локальности прогноза за счёт механизма пространственной агрегации признаков. В данной архитектуре состояние каждого узла (аэропорта) на каждом слое сети обновляется путём интеграции векторов признаков связанных с ним рёбер (рейсов) и соседних узлов. Это позволяет модели транслировать информацию о спросе через промежуточные точки и учитывать возвратные маршруты.

Математически процесс распространения информации и обновления признаков в слое GCN описывается следующей формулой:

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right) \tag{8}$$

Где:

- $H^{(l)}$ — матрица эмбеддингов узлов на слое l (где $H^{(0)}$ представляет собой исходные признаки аэропортов);
- $W^{(l)}$ — обучаемая матрица весов слоя l;
- σ — нелинейная функция активации (например, ReLU);
- $\tilde{A} = A + I_n$ — модифицированная матрица смежности графа авиасети A с добавлением единичной матрицы I_n для учёта петель самосвязи узлов;
- $\tilde{D}$ — диагональная матрица степеней узлов для матрицы $\tilde{A}$, элементы которой задаются как $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$.

Операция симметричной нормализации $\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}$ предотвращает изменение масштаба признаковых векторов при прохождении через слои сети. Благодаря этой операции эмбеддинг каждого рейса за T недель до вылета ($T \in \{2, 4, 6, 8\}$) начинает содержать в себе сжатую информацию о состоянии всей релевантной части авиасети. Данная архитектура и её модификации доказали свою высокую эффективность при извлечении нетривиальных пространственных закономерностей как в общих задачах полуавтоматической классификации графовых структур [4], так и в крупномасштабных рекомендательных системах на основе веб-графов [5].

3.3 Графовые сети с механизмом внимания (GAT)

Несмотря на эффективность графовых свёрточных сетей, их существенным ограничением является механизм статической агрегации: при вычислении нового состояния узла признаки всех его соседей учитываются с фиксированными весами, определяемыми лишь структурой графа. В реальности влияние различных аэропортов и рейсов друг на друга неоднородно.

Для решения этой проблемы в работе используется архитектура графовых сетей с механизмом внимания (Graph Attention Networks, GAT) [6]. Ключевым отличием GAT является введение обучаемых коэффициентов внимания α_{ij}, которые позволяют сети динамически определять значимость каждого соседа j для целевого узла i в зависимости от их текущих признаков.

Математически механизм внимания в GAT реализуется следующим образом. Для пары связанных узлов i и j сначала вычисляется коэффициент подобия (энергия внимания):

$$e_{ij} = a(W\mathbf{h}_i, W\mathbf{h}_j) \tag{9}$$

Где W — общая матрица линейного преобразования признаков, а a — обучаемая функция внимания, реализованная в виде однослойной нейронной сети. Для перевода коэффициентов в распределение вероятностей используется оператор softmax по всему множеству непосредственных соседей узла i (обозначим его как $\mathcal{N}_i$):

$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \frac{\exp\left(\text{LeakyReLU}\left(\vec{a}^T[W\mathbf{h}_i \parallel W\mathbf{h}_j]\right)\right)}{\sum_{k\in\mathcal{N}_i}\exp\left(\text{LeakyReLU}\left(\vec{a}^T[W\mathbf{h}_i \parallel W\mathbf{h}_k]\right)\right)} \tag{10}$$

где $\vec{a}$ — вектор весов функции внимания, а $\|$ обозначает операцию конкатенации векторов. Функция активации LeakyReLU применяется с параметром наклона $\gamma = 0.2$ (см. формулу (3) в разделе 2).

Итоговое обновлённое представление узла формируется как взвешенная сумма признаков его соседей:

$$\mathbf{h}_i^{(l+1)} = \sigma\left(\sum_{j \in \mathcal{N}_i} \alpha_{ij} W \mathbf{h}_j^{(l)}\right) \tag{11}$$

Для повышения стабильности обучения и расширения ёмкости модели применяется многоголовое внимание (multi-head attention). В этом случае вычисление повторяется независимо для K различных головок, а результаты конкатенируются:

$$\mathbf{h}_i^{(l+1)} = \Big\|_{k=1}^{K} \sigma\left(\sum_{j \in \mathcal{N}_i} \alpha_{ij}^k W^k \mathbf{h}_j^{(l)}\right) \tag{12}$$

Применение GAT позволяет модели гибко адаптироваться к изменяющейся ситуации на рынке авиаперевозок. Использование нескольких голов внимания позволяет модели одновременно отслеживать различные типы зависимостей: от долгосрочных сезонных колебаний до краткосрочных всплесков локального спроса. На практике подобные архитектуры с механизмами анизотропного внимания доказали свою эффективность при моделировании сложных динамических процессов, включая предсказание трафика в сильно связанных транспортных узлах [7] и индуктивное обучение на распределённых пространственно-временных графах [6].

4 Описание экспериментов

В данном разделе описывается программно-аппаратурный комплекс проведения вычислительных экспериментов, фиксируются схемы подбора гиперпараметров, а также приводится структура сравнительного анализа разработанных моделей.

4.1 Характеристики данных и схема разбиения

В качестве эмпирической базы исследования используются данные о пользовательской активности (кликах) в системе поиска и бронирования авиабилетов за период с 1 июня 2022 года по 30 апреля 2024 года. Каждая запись содержит информацию о параметрах рейса и количестве кликов пользователей на различных временных горизонтах до даты вылета.

Для обеспечения чистоты эксперимента из исходного набора были исключены данные за первые и последние 50 дней рассматриваемого периода. Это обусловлено необходимостью наличия полной истории наблюдений для каждого рейса.

Разбиение очищенного набора данных на выборки производилось в строгом хронологическом порядке. Такой подход полностью исключает риск утечки данных и позволяет объективно оценить обобщающую способность моделей в условиях реальной эксплуатации:

- **Обучающая выборка** включает в себя первые 400 дней. Данный интервал используется для оптимизации внутренних параметров моделей.
- **Валидационная выборка** охватывает следующие 100 дней. Она применяется для подбора гиперпараметров и выбора архитектурных решений.
- **Тестовая выборка** состоит из финальных 100 дней. Этот набор используется исключительно для независимой оценки качества прогнозирования и сравнения моделей.

Специфика рассматриваемого набора данных накладывает ряд существенных ограничений на процесс моделирования. Выделяются следующие ключевые особенности:

1. **Выраженная сезонность.** Пользовательский спрос подвержен циклическим колебаниям разной периодичности (суточным, недельным и годовым), а также резким всплескам активности в периоды праздников и отпусков.

2. **Высокая степень разреженности.** Под разреженностью в данной работе понимается свойство распределения целевой переменной, при котором для подавляющего большинства доступных в расписании авиарейсов количество зафиксированных переходов строго равно нулю или близко к нему в силу эпизодичности спроса на непопулярных маршрутах.

Прямое применение регрессионных моделей к выборкам с таким распределением целевой переменной приводит к существенному смещению прогнозов в сторону среднего значения и ухудшает сходимость алгоритмов. Для решения проблемы разреженности внедряется этап предварительной фильтрации: задача разделяется на две подзадачи. На первом шаге решается задача бинарной классификации, в рамках которой все рейсы разделяются на категории потенциально востребованных и невостребованных. Выделение невостребованных перелётов позволяет отсеять пустые сегменты рынка и сфокусировать регрессионные модели исключительно на подмножестве объектов с ненулевой активностью.

4.2 Настройка моделей и гиперпараметры

Эксперименты проводятся в соответствии со схемой временной валидации, описанной выше. Подбор оптимальных конфигураций моделей и их гиперпараметров осуществляется на валидационной выборке, после чего финальные оценки вычисляются на независимом тестовом множестве.

Для базовой модели CatBoost, обучаемой на минимизацию функционала качества RMSE, настраиваются следующие ключевые параметры: глубина решающих деревьев, скорость обучения и коэффициент L_2-регуляризации.

Для графовых нейронных сетей (GCN и GAT) входные векторные представления формируются путём объединения локальных признаков рейсов и структурных эмбеддингов аэропортов. Обучение нейросетевых архитектур выполняется с использованием оптимизатора Adam. В качестве целевой функции потерь применяется минимизация среднеквадратичной ошибки. Для GAT используется многоголовое внимание с количеством голов $K = 4$.

Качество моделей оценивается по метрикам MAE, RMSE и R^2, определённым в разделе 2.3.

4.3 Анализ результатов и сравнение моделей

В ходе вычислительных экспериментов было проведено последовательное тестирование базового табличного подхода и разработанных графовых архитектур для каждого из целевых временных горизонтов на очищенных данных востребованных перелётов. Сводные результаты сравнительного анализа точности моделей на тестовой выборке представлены в таблице 1.

Анализ полученных результатов позволяет сделать следующие выводы.

Сравнение табличного и графовых подходов. Базовая модель CatBoost демонстрирует наилучшие показатели на всех временных горизонтах. Это объясняется тем, что в задаче прогнозирования спроса на авиаперевозки индивидуальные признаки рейса (авиакомпания, день недели, месяц, время вылета) вносят более существенный вклад в точность прогноза, чем пространственный контекст маршрутной сети. Кроме того, CatBoost эффективно

Таблица 1: Сравнение точности прогнозирования спроса (MAE / RMSE / R^2) на различных временных горизонтах

Модель	**2 недели**	**4 недели**	**6 недель**	**8 недель**
CatBoost	7.23 / 12.65 / 0.110	9.12 / 15.97 / 0.102	10.79 / 18.88 / 0.104	12.35 / 21.59 / 0.101
GCN	9.57 / 16.79 / 0.054	12.35 / 20.12 / 0.048	14.57 / 23.46 / 0.042	16.79 / 27.89 / 0.038
GAT	8.90 / 15.43 / 0.067	11.57 / 18.90 / 0.059	13.46 / 22.12 / 0.052	15.68 / 26.12 / 0.048

работает с разреженными данными и высокоразмерными категориальными признаками за счёт встроенных механизмов обработки.

Сравнение графовых архитектур между собой. Модель GAT превзошла GCN на всех горизонтах прогнозирования. Это подтверждает теоретическое преимущество механизма динамического внимания перед изотропной свёрткой: GAT способна адаптивно назначать веса соседним узлам в зависимости от их значимости, тогда как GCN усредняет всех соседей с фиксированными коэффициентами, определяемыми только структурой графа.

Динамика по временным горизонтам. Для всех моделей наблюдается закономерный рост ошибок с увеличением прогнозного горизонта: чем дальше от даты вылета, тем сложнее предсказать пользовательскую активность. Наибольшее относительное ухудшение качества наблюдается у графовых моделей, что может свидетельствовать о том, что пространственные зависимости становятся менее информативными на дальних горизонтах прогнозирования по сравнению с локальными признаками рейса.

Таким образом, хотя графовые нейронные сети не превзошли классический градиентный бустинг в данной задаче, они продемонстрировали сопоставимые результаты, а архитектура с вниманием (GAT) ожидаемо оказалась эффективнее свёрточной (GCN). Полученные результаты указывают на перспективность дальнейших исследований в направлении гибридных моделей, комбинирующих сильные стороны табличных и графовых подходов.

5 Заключение

В ходе выполнения данной курсовой работы было проведено исследование эффективности применения графовых нейронных сетей для прогнозирования интенсивности пользовательского спроса на авиаперевозки. Топология маршрутной сети была формализована в виде ориентированного графа, что позволило объединить локальные признаки рейсов и аэропортов в едином математическом представлении. Для решения проблемы разреженности целевой переменной был применён двухэтапный подход с предварительной фильтрацией невостребованных рейсов.

Для сравнительного анализа был реализован базовый табличный подход на основе алгоритма градиентного бустинга CatBoost, а также разработаны модели на основе архитектур графовых свёрточных сетей (GCN) и графовых сетей с механизмом внимания (GAT). Вычислительные эксперименты, проведённые на независимой тестовой выборке для горизонтов в $2, 4, 6$ и 8 недель до вылета, показали, что классический алгоритм CatBoost демонстрирует наилучшую точность прогнозирования на всех временных горизонтах. Среди графовых архитектур модель GAT ожидаемо оказалась эффективнее GCN благодаря механизму динамического внимания, что подтверждает теоретические преимущества данного подхода перед изотропной свёрткой. Для всех моделей наблюдается закономерный рост ошибок с увеличением прогнозного горизонта.

Несмотря на то, что графовые нейронные сети не превзошли градиентный бустинг в рамках данной задачи, они продемонстрировали сопоставимые результаты, а архитектура GAT показала устойчивое преимущество над GCN. Разработанный подход имеет прикладную ценность для авиакомпаний при оценке востребованности маршрутов, особенно в задачах,

где структурные взаимосвязи между перелётами (например, стыковочные или возвратные рейсы) играют более значимую роль. Полученные результаты открывают перспективы для дальнейших исследований в направлении гибридных моделей, комбинирующих сильные стороны табличных и графовых подходов.

Список литературы

[1] Gori M., Monfardini G., Scarselli F. A new model for learning in graph domains // Proceedings of the IEEE International Joint Conference on Neural Networks (IJCNN). — 2005.

[2] Scarselli F., Gori M., Tsoi A. C., Hagenbuchner M., Monfardini G. The graph neural network model // IEEE Transactions on Neural Networks. — 2009.

[3] Yandex. CatBoost: высокопроизводительная библиотека градиентного бустинга // Официальный сайт. — 2017. — URL: https://catboost.ai

[4] Kipf T. N., Welling M. Semi-supervised classification with graph convolutional networks // International Conference on Learning Representations (ICLR). — 2017.

[5] Ying R., He R., Chen K., Eksombatchai P., Hamilton W. L., Leskovec J. Graph convolutional neural networks for web-scale recommender systems // Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — 2018.

[6] Veličković P., Cucurull G., Casanova A., Romero A., Liò P., Bengio Y. Graph Attention Networks // International Conference on Learning Representations (ICLR). — 2018.

[7] Zheng G., Fan X., Wang C., Jiao J. GMAN: A Graph Multi-Attention Network for Spatial-Temporal Traffic Forecasting // Proceedings of the AAAI Conference on Artificial Intelligence. — 2020.

[8] Song C., Lin Y., Guo S., Wan H. Spatial-Temporal Synchronous Graph Convolutional Networks: A New Framework for Spatial-Temporal Network Data Forecasting // Proceedings of the AAAI Conference on Artificial Intelligence. — 2020.

[9] Li M., Zhu Z. Spatial-temporal fusion graph neural networks for traffic flow forecasting // Proceedings of the AAAI Conference on Artificial Intelligence. — 2021.